

面向多通道时序数据的可复用异常检测流程

赛道：AI + 学科交叉

作品简介

电池运维与服务器监控属不同学科，却面对同一类问题：无故障标签、通道语义异构，代码与单一场景深度耦合，换数据即需重写。本作品把电池电压研究代码提炼为可独立安装的 Python 算法库，用统一 (N,T,C) 契约连接「正常参考拟合 → 独立校准 → 因果连续报警 → 通道证据 → 严格逐点评价」五阶段流程，并用 peer / independent 两种特征模式适配不同学科的通道语义。库在两场景完成 40 组固定协议实验，配 120 项测试与 SHA256 溯源。工程封装与接口复用已完成，检测效果仍有限：服务器三机宏平均严格 F1 仅 0.11–0.29，电池只验证正常参考上的报警率。本作品不主张新算法，也不代表可直接用于安全控制。

诚实声明（贯穿全文的写作原则）：本作品所要主张的是**检测流程与评估协议的可复用性**，而不是一种新的检测算法。所用 robust、LOF、Isolation Forest、PCA 四种方法均为已发表的既有工作，本作品不声称对其作出原创性改进，也不声称已取得领先或生产可用的检测性能。全文所有实验数字均来自本作品实际运行的固定协议实验，未作任何修饰或择优拼接。

1 需求分析

1.1 两个学科场景，同一类技术问题

本作品源于一个跨学科的现实观察：**电池储能运维与服务器系统监控**看似属于材料 / 电气与计算机两个相距甚远的学科，但在"用无监督方法发现多通道时序数据中的异常"这一环节上，它们面临的技术约束几乎完全重合。

在电池场景中，一个电池包内 8 个串联单体是可相互比较的同类通道，单体电压之间的相对偏离蕴含单体级故障线索；在服务器场景中，一台机器的 38 个监控通道（CPU、内存、磁盘、网络等）是量纲互不相同的异构通道。两者的共同点是：（i）真实故障标签稀缺乃至不存在，监督学习不可用；（ii）正常参考数据相对易得，可用于刻画"正常应该长什么样"；（iii）告警必须满足因果性——不能用未来数据判断当前点是否异常，否则无法在线部署；（iv）在生产中误报成本高昂，"连续几窗确认后才报警"比"单点超阈值即报警"更可接受。

因此，两个学科场景真正需要的并不是"又一个检测模型"，而是一套**与具体物理量、具体领域解耦、可被不同学科直接复用的检测流程与评估协议**。这正是本作品的出发点。

1.2 现有做法的三处断裂

在本作品开始整理前，团队原有的电池检测研究代码已经能够跑出结果，但其结构存在三处影响跨学科复用的断裂，它们在跨领域迁移时逐一暴露：

断裂点	问题表现	对跨学科复用的影响
特征断裂	特征提取与"电压单体"这一具体物理量硬绑定，统计量、通道选取都写死在电池代码里。	换成服务器监控这类异构通道时无法直接使用，必须重写特征层，且容易把不同量纲的通道错误混合。
校准断裂	阈值、标准化参数来自同一个被观察的数据集，拟合、校准、评价边界不清，存在信息泄漏与事后调阈值的风险。	换领域后阈值失去意义；若沿用同一套阈值选择逻辑，会得到"看起来很好但不可复现"的结果。
评价断裂	评价采用逐点指标但常隐含 point adjustment——事件内命中一次就把整段补为检出，抬高指标。	不同学科、不同团队的结果无法横向比较，也无法判断迁移后到底是变好还是变差。

1.3 为什么需要"可复用流程"而不是"更复杂的模型"

一个自然的直觉是：既然检测效果有限，就应该上更深的模型（如深度自编码器、LSTM 预测残差等）。本作品**没有**走这条路，理由有三点，且都有本次实验的证据支撑：

- **数据规模不支持。**本作品可用的电池正常参考共 26508 窗、服务器三机共 80873 个测试点，且电池侧完全没有真实故障标签。在这种规模下训练深度模型，其增益无法被可靠地验证。
- **评价协议的重要性不低于模型。**第 4.2 节将展示：同一个 LOF 模型，仅仅因为评价协议是否做 point adjustment、以及时序窗口长度取 1 还是 16，就会呈现出从"三机宏平均 F1 0.2379"到"0.1260"的巨大差异。这说明**先统一协议，再谈模型**是更有效的路径。
- **复用的瓶颈在接口而非算法。**第 4.3 节的尺度对照实验说明，跨场景失效往往来自特征与尺度的不匹配，而这属于接口层的设计问题，不是换一个更强的算法就能解决的。

据此，本作品的定位确定为：**把既有方法组织成一条标准化的、可校准、可复现、可严格评价的流程，并把这套流程封装为可独立安装的库。**

2 技术方案

2.1 统一数据与输出契约

跨学科复用的第一道关口是数据表示。本作品定义了一个与具体物理量无关的统一输入契约：

- **输入**为三维有限数值数组 (N, T, C)：N 为有序窗口数，T 为窗口长度，C 为通道数。输入必须非空、三维且全部有限；NaN 与无穷会被**显式拒绝**，不做静默填补。拟合至少 3 窗、校准至少 2 窗（这是 API 下限，不是统计充分性的保证）。
- **通道语义由调用方声明**。库不自动识别单位、频率、时间戳或采样间隔；通道顺序或窗口长度改变时必须重新拟合与校准——**相同形状不代表相同物理含义**。
- **输出**为结构化对象：异常分数 scores、阈值 threshold、超阈值标记 exceeded 与连续确认标记 confirmed、报警起止边沿 alarm_started / alarm_cleared、通道证据 channel_evidence 及其排序 ranked_channels，以及可供下一连续块复用的状态 state。

契约中刻意保留了两条"拒绝服务"的设计：其一，一个 predict 调用只能对应 **同一设备的一段连续有序序列**，库不检查时间戳，连续性须由调用方保证；其二，state 绑定设备与模型 / 校准版本，重新拟合或校准后旧状态会被拒绝，不能跨设备复用。这两条设计把"边界正确性"的责任明确划给调用方，避免了跨学科场景中最常见的隐性错误。

2.2 五阶段流程

在统一契约之上，本作品把检测组织为五个明确分离的阶段，每个阶段的职责与可见信息都被严格限定。其中检测内核采用四种**既有**方法——鲁棒绝对偏差、LOF^[1]、Isolation Forest^[5] 与 PCA 重建残差；本作品不修改其算法本身，只统一其输入契约、校准方式与评价协议。整体范式属于基于正常参考的 novelty detection^[2]。

阶段	名称	职责与约束
①	正常参考拟合	仅用业务确认的正常参考数据估计标准化参数（中位数中心 + 1.4826×MAD 尺度）与模型内部结构。拟合侧按时间顺序均匀抽样，最多 6000 窗。
②	独立校准	在 与拟合段不重叠 的独立正常校准段上计算分数分布，取 q99 作为阈值。修正后阈值不随测试数据变化。
③	因果连续报警	严格 score > threshold；连续 5 窗超阈值才 从第 5 窗起 确认，不回填前 4 窗。一窗未超阈值即解除。
④	通道证据排序	输出每个通道的标准化偏离量并排序，用于人工核验线索， 不是 模型分数的归因分解。

⑤	严格逐点评价	逐点指标不做 point adjustment; FPR 分母为实际正常点; 事件延迟只统计已检出事件。
---	--------	--

时序切分固定为**按时间顺序的 60% 拟合 / 20% 校准 / 20% 验证**，随机种子 seed 42。这五阶段的分工，是本作品"方案可行性"的直接来源：任何一步出错都能被单独定位（第 4.3 节的尺度实验正是借这套分工才找到根因）。




图 1 流程实例：本图展示的是上述五阶段流程**在电池场景上的一个具体实例**（256×20 输入 → 32 维单体相对中位数残差 → 中位数 / MAD 标准化 → LOF 新样本评分 → 连续 5 窗确认），**并非通用流程图**。换到服务器场景时，特征模式、维度与所用方法均可替换，而五阶段骨架保持不变。

2.3 两种特征模式：面向学科语义的适配层

跨学科复用最实际的困难在于"通道之间能不能比较"。本作品没有回避这一点，而是显式提供两种特征模式，把选择权交给使用学科：

特征模式	每通道统计量	使用边界
independent	均值、标准差、极差、归一化时间轴上的线性斜率、差分标准差	不直接混合不同通道的物理量，适用于 异构监控通道 ；仍需每通道正常参考标准化。
peer	相对通道中位数残差的均值、标准差、绝对残差 q95、残差差分标准差	要求至少 2 个 物理可比较的同类通道 ，不能混合电压、温度、转速等不同单位。

这一区分直接对应两个学科场景：电池的 8 个串联单体电压彼此可比，用 peer，其核心统计量是"某单体相对全部单体中位数的残差"；服务器的 38 个通道量纲各异，用 independent，逐通道独立统计。**正是这条适配层，使同一套代码得以在两类数据上运行，而不需要改写检测内核。**

标准化一律采用**中位数中心 + 1.4826×MAD 尺度**，而非均值 / 标准差，理由来自对异常敏感的鲁棒统计实践^[3]。针对稀疏变化特征（大部分时间不变、偶有变化）可能出现的**零 MAD**退化，本作品建立了显式的回退规则：当 $MAD < 1e-7$ 且拟合侧标准差 $\geq 1e-7$ 时，回退到拟合侧标准差；否则按

MAD 处理并设 $1e-7$ 下限。该规则的定位是**已定位工程缺陷的修正**，不是原创算法（见 4.4 节第 4 条与第 8 条）。

2.4 因果性与防泄漏

在线检测的可用性取决于两点：**不用未来信息**，且**不把评价信息回流到建模**。本作品的处理是：

- **先划分角色，再构造窗口**。原始序列先按时间顺序切为拟合 / 校准 / 验证三段，再各自构造窗口，避免拟合窗口与校准窗口跨边界共享原始采样点。窗口只含末端及其之前的数据。
- **标准化参数只来自拟合侧**。中心、MAD 与退化回退标准差全部只在拟合段计算；校准与测试段**不会更新**它们。
- **标签只用于评价**。测试标签不进入模型拟合、阈值校准或参数选择。
- **分块一致性**。同一连续序列分块预测时原样传递状态，其报警结果与整段一致；换设备或独立序列必须显式重置状态，否则边界附近的连续确认会改变。

必须同时声明的边界：电池输入是**已构造好的缓存窗口**，缓存没有时间戳与步长，因此本作品**无法独立核实**相邻窗口是否在原始采样层重叠，**不能宣称已排除全部原始点级泄漏**。另外，当 $T = 16$ 时独立测试段前 15 个点是预热区，不产生输出，评价必须明确这一覆盖范围，不得把预热区补为正常预测后混入指标。

2.5 严格评价：为什么不做 point adjustment

时序异常检测领域长期存在一个被广泛批评的评价惯例——point adjustment，即只要一个异常事件内有一个点被正确命中，就把该事件内所有点都替换为命中。这会系统性地高估模型能力^[4]。本作品**明确拒绝**该惯例：

- 逐点指标直接使用 confirmed 标记计算，一次命中不会把整个事件补为检出。
- FPR 的分母是**实际正常点**；只有正常数据可用时，**只能报告正常报警率**，不能评价真实故障的 Recall / F1。
- 事件延迟只统计**已检出**事件，从事件开始到首次确认的采样点偏移，未检出事件不计“零延迟”。

这套协议是跨学科结果可比较的前提，也是本作品“方案可行性”得分的核心依据之一：任何人用同一套协议复跑，都能得到可对比的数字。

2.6 设计原则：不追求跨领域自动迁移

本方案最重要的设计原则是**克制**——明确不承诺“跨领域自动迁移”，因为这种承诺在无监督异常检测中不可兑现。换一个场景，本作品要求使用者显式提供：正常参考数据、明确的通道语义、合适的特征模式，并**重新拟合与校准**。这不是缺陷，而是对本类问题数据本质的尊重。

创新点定位（避免夸大）：本作品的创新性在于**工程与评估层面**——把碎片化的场景代码提炼为统一契约的库、区分同类 / 异构通道两种特征语义、把独立校准与因果连续报警固化为流程、并坚持不做 point

adjustment 的严格评价。本作品**不主张**新的检测算法，**不主张**现有方法的改进，**不主张**跨领域自动迁移能力。

3 项目实施

3.1 交付形态：可独立安装的库

为了让流程真正可被他人复用，本作品没有停留在"研究脚本"，而是交付一个**可独立安装的 Python 包**：发行名 `chronoguard-ts`，导入名 `chronoguard`，版本 0.1.0。交付物为 wheel 与源码包 (sdist) 两种形态，均**不含**私有数据、下载数据、模型、逐点预测、Git 历史、缓存或日志。

- **核心库共 393 行、5 个模块**，分别为 `detector.py`（拟合、校准、因果预测、分块状态、模型持久化）、`features.py`（两种特征模式与通道适配）、`data.py`（因果构窗、角色切分、外部数据读取与校验）、`evaluation.py`（严格逐点指标、报警区间、正常序列报警率）、`__init__.py`。
- **零重依赖**：核心流程不需要 PyTorch、CUDA、MATLAB 或 Office；仅依赖 NumPy、scikit-learn、joblib，实验间接使用 SciPy 与 `threadpoolctl`，绘图为可选的 `[plot]` 依赖。这使得库可以部署在没有 GPU 的普通环境。
- 已验证环境为 Python 3.12.14、NumPy 2.5.2、SciPy 1.18.1、scikit-learn 1.9.1、joblib 1.6.0、`threadpoolctl` 3.7.0、`matplotlib` 3.11.2。

3.2 测试与隔离安装验证

"能在自己机器上跑"与"能被别人装起来跑"是两回事。本作品对后者做了专门验证：

验证项	结果
新库单元测试	34 项，覆盖变通道输入、有限值检查、原电池 <code>peer</code> 特征等价、MAD 退化、拟合 / 校准分离、因果性、分块一致、设备边界、状态失效、模型加载、窗口对齐、严格评价。
原研究体系回归测试	86 项，检测流程的回归测试保留。
合计	120 项，0 失败。
wheel 在仓库之外的干净虚拟环境安装	核对导入来源并跑通四种方法，导入成功。
源码包解压后独立安装	34 项测试通过（其中 1 项因依赖库内文件缺失而 跳过 而非失败），并成功运行示例。

关于那 1 项跳过：库内有一项 `peer` 等价测试需要加载原研究体系的 `features.py` 做逐值比对。该文件只在完整源码仓库内存在，单独发布 `framework/` 时对应测试会跳过而非失败——这是**刻意**的设计，保证发布的精简包不会因缺少内部文件而报错。

3.3 实验规模

数据域	规模	协议要点
电池（正常留出）	4 个正常包共 26508 窗	包 6/8/9/10 轮流留出，其余包各自按时间分段；peer 特征。
服务器 SMD	3 台机器共 80873 个测试点	machine-1-1 / -2-1 / -3-1 分别拟合 / 校准 / 测试；T=1、C=38、independent 特征。
实验总数：两类场景共 40 组 = 28 组原始（16 组电池 + 12 组 SMD）+ 12 组时序尺度对照（T=16）。所有组采用同一固定协议：q99 阈值、连续 5 窗确认、seed 42、最多 6000 拟合窗。		

3.4 哈希溯源

为了让结果可被独立核对，本作品对**源码、输入数据、模型、产物**四类对象建立了完整的 SHA256 溯源：本次共核对 49 个产物哈希与 12 个输入哈希，12 组 SMD 指标从保存的逐点预测重新计算并与汇总一致。provenance.json 保存固定协议、版本与源码 / 输入 SHA256。对第三方服务器数据，库在下载清单存在时会核对来源、三类文件清单项与 SHA256，**不符或缺项即拒绝读取**。

溯源的边界：SHA256 只说明字节一致性，**不证明**数据真实性、无泄漏或模型来源可信。哈希本身不能替代人工核验；攻击者可以同时替换对象与其哈希。

4 应用效果

4.1 电池场景：正常参考上的确认报警率

电池数据**没有真实故障标签与可靠时间映射**，因此本作品只能报告正常参考上的确认报警率，**不能**计算真实故障召回率、F1、提前量或单体定位准确率。下表为全部留出窗口被视为正常参考时的确认报警窗口比例，宏平均为四包比例的**算术平均**，不是按窗数加权。

方法	包6	包8	包9	包10	四包宏平均
robust	0.186%	0.144%	0.020%	0.000%	0.087%
lof	0.866%	18.453%	0.098%	8.238%	6.914%
iforest	0.000%	0.000%	0.020%	0.000%	0.005%
pca	0.011%	2.153%	0.157%	0.000%	0.580%

LOF 分数曲线：电池正常留出包




图 2 电池四个留出包的 LOF 分数曲线与正常校准阈值。可见包 8 与包 10 存在大量超阈值区间。

包 8 的 18.453% 不能表述为“误报”。电池“训练数据保证无故障”这一前提**未获证实**，且**现有证据对它不利**：所依据的公开数据集官方 README 声明全部 28 个系统均因“不满意行为”退回厂家，且明确说明该数

据集有偏、不代表总体运行数据^[7]。因此在取得时间映射之前，包 6/8/9/10 上的高报警率应表述为“未解释的跨包报警”，而不是“正常数据误报”。这一措辞上的克制，是本方案可行性的组成部分。

4.2 服务器场景：严格逐点指标

服务器数据有逐点标签，可计算严格逐点指标（不做 point adjustment）。所有逐点指标使用 confirmed； $FPR = FP / (FP + TN)$ ，分母为正常点；事件由连续阳性标签定义。

机器	方法	Precision	Recall	严格 F1	正常点 FPR	事件检出/总数
machine-1-1	robust	0.2534	0.9324	0.3984	28.710%	7/8
machine-1-1	lof	0.2807	0.7238	0.4046	19.376%	7/8
machine-1-1	iforest	0.5409	0.1522	0.2375	1.350%	4/8
machine-1-1	pca	0.1641	0.8296	0.2740	44.154%	8/8
machine-2-1	robust	1.0000	0.0547	0.1037	0.000%	3/13
machine-2-1	lof	0.7196	0.1667	0.2706	0.337%	6/13
machine-2-1	iforest	0.6000	0.0128	0.0251	0.044%	2/13
machine-2-1	pca	0.7381	0.0265	0.0512	0.049%	3/13
machine-3-1	robust	0.9524	0.1299	0.2286	0.007%	1/4
machine-3-1	lof	0.0199	0.5292	0.0384	28.219%	4/4
machine-3-1	iforest	0.0375	0.3604	0.0680	10.031%	1/4
machine-3-1	pca	1.0000	0.2662	0.4205	0.000%	1/4

方法（三机宏平均）	宏平均 Precision	宏平均 Recall	宏平均严格 F1	宏平均正常点 FPR
robust	0.7352	0.3723	0.2436	9.573%
lof	0.3401	0.4732	0.2379	15.977%
iforest	0.3928	0.1751	0.1102	3.808%
pca	0.6341	0.3741	0.2486	14.734%

宏平均为同一固定方法在三台机器上各指标的算术平均；F1 列是三台 F1 的均值，不是从宏平均 Precision/Recall 再计算的 F1。**本作品未挑选各机器测试最优方法拼接成绩**，因为那是不可复现的做法。machine-3-1 的 LOF 虽命中 4/4 个事件，FPR 却高达 28.219%、严格 F1 仅 0.0384——这说明“事件全命中”不能独立作为高效能结论。

LOF 分数曲线：SMD (对数纵轴)




图 3 SMD 三机的 LOF 分数曲线 (T=1 逐点基线, 纵轴对数, 橙色虚线为正常校准 q99 阈值)。

4.3 核心贡献：时序尺度对照实验与距离对比度机理

本节是本作品**最具方法论价值**的部分，也是“方案可行性”评分项的核心证据。它回答了一个跨学科复用中至关重要的实际问题：**把同一套流程迁移到另一个场景时，方法为什么会失效？**

本作品设计了严格的对照实验：**同一份数据、同一套代码、同一套协议 (q99 / 连续 5 窗 / seed 42 / 最多 6000 拟合窗)**，**唯一改变的是窗口长度 T** (T=1 的逐点基线与 T=16 的开窗)，从而把“时序尺度”这一变量的影响单独隔离出来。

方法	T = 1 宏平均严格 F1	T = 16 宏平均严格 F1	变化
robust	0.2436	0.2933	+0.0497
lof	0.2379	0.1260	-0.1119
iforest	0.1102	0.1703	+0.0601
pca	0.2486	0.2463	-0.0023




图 4 四方法 × 两尺度的宏平均严格 F1 对比, 图中诊断框给出特征空间的成对距离对比度。


机理：距离对比度的塌缩。实验给出的特征空间诊断揭示了根因。在 machine-3-1 的校准集 800 点子样本上 计算特征空间点对距离的变异系数 (CV) 与 p95/p5 对比度：

尺度	有效特征维度	点对距离 CV	p95 / p5 对比度
T = 1	30	3.455	65.8×
T = 16	150	0.404	3.1×

随着窗口长度增大, 有效特征维度从 30 升到 150, 数据在特征空间中**越来越"拥挤"**, 点与点之间的相对距离差异被压缩 (p95/p5 对比度从 65.8× 塌缩到 3.1×, CV 从 3.455 降到 0.404)。此时**"邻居明显近于非邻居"这一前提不再成立**, 而 LOF 的局部可达密度恰恰建立在该前提之上^[1], 于是 LOF 的判别力被直接削弱; robust、PCA、Isolation Forest 不依赖邻居对比, 未出现同等退化。这解释了为什么上表中只有 LOF 出现了 -0.1119 的显著下降。

效应还**因机器而异**: machine-1-1 的 LOF 宏 F1 从 0.4046 降到 0.1577 (召回塌陷), machine-2-1 从 0.2706 降到 0.1645, 而 machine-3-1 反而从 0.0384 微升到 0.0558。说明尺度效应与具体数据的维度 / 冗余结构有关, 不能简化为"T 越大越差"的单一结论。

同一套流程，两个时序尺度：SMD 上 LOF 的表现



红色背景：标签中的异常区间；橙色虚线：各模型正常校准 q99 阈值。纵轴均为对数。T=16 已把窗口末端对齐到原始点序号；前 15 点为预热区，不生成输出。

图 5 (核心图) 三机器 × 两尺度 (T=1 左 / T=16 右) 的 LOF 分数并排对比，含阈值与真实异常区间。左列为逐点基线；右列为 T=16 开窗。注意 T=16 的分数曲线整体被压平、与阈值的区分度下降，与上文“距离对比度塌缩”的机理一致。

这一实验的价值不限于解释 LOF：它给出了一条**可迁移的复用诊断方法**——在把流程迁移到新场景前，先测量特征空间的成对距离对比度，即可预判哪种方法可能失效。这正是本作品把“评估流程”与“检测流程”并列为核心交付的实证理由。

4.4 局限与边界 (完整陈述)

以下 8 条局限是本作品不可回避的边界。完整陈述它们，而非淡化，既是本作品一贯的风格，也是方案可行性的一部分。

1. **检测效果有限。** SMD 三机宏平均严格 F1 仅为 0.11–0.29；电池场景只有正常参考上的报警率，**没有真实故障召回率。**
2. **电池“训练数据无故障”的前提未获证实，且现有证据对它不利。** 所依据的公开数据集官方 README 声明全部 28 个系统均因“不满意行为”退回厂家。因此不能假定留出包 6/8/9/10 是无故障的正常参考，包 8 的 18.453% **不能表述为“误报”，** 应表述为“未解释的跨包报警”。

3. **SMD 只覆盖 3 台机器**（数据集共 28 台）；且 $T=1$ 时除均值外的时序统计量为零，本作品在 SMD 上是明确的**逐点基线**，不代表已具备复杂时序建模能力。
4. **尺度修正发生在已查看同一测试集结果之后**，属**开发复验**而非全新盲验；结果不能包装为"未见测试集验证"。
5. **电池缓存无时间戳**，无法独立核实相邻窗口是否共享原始采样点，不能宣称已排除全部原始点级泄漏。
6. **通道证据是辅助偏离量，不是 LOF / Isolation Forest 分数的归因分解**，也不等于故障根因定位或真实单体定位准确率。
7. **许可约束**：所依据的电池现场数据集为 **CC-BY-NC-4.0**，含 NC（非商业）条款。用于本次校园算法竞赛（AI+学科交叉）属非商业用途；**不得用于商业化场景或创新创业类赛道**。引用须署名并给出 DOI。
8. **本作品解决的是流程复用问题，不主张新的检测算法**；MAD 退化的回退规则是已定位工程缺陷的修正，应表述为工程修正，而非原创检测方法。

5 总结与展望

5.1 总结

本作品围绕"让异常检测流程能跨学科复用"这一目标，完成了三项具体工作：

- **把碎片化的场景代码提炼为标准化流程与可安装库。**定义统一 (N, T, C) 输入契约与结构化输出契约，固化"正常参考拟合 → 独立校准 → 因果连续报警 → 通道证据 → 严格逐点评价"五阶段，并以 393 行核心代码、5 个模块交付，无 GPU / MATLAB 依赖。
- **用两个学科场景验证了流程的可用性。**电池（4 包 26508 窗）与服务器监控（3 机 80873 点）在同一套接口与协议下完成 40 组实验，配 120 项测试与完整 SHA256 溯源。
- **给出了迁移失效的可诊断机理。**通过只改变窗口长度的严格对照实验，定位到"特征空间点对距离对比度塌缩"这一根因，并说明为何依赖邻居对比的 LOF 会退化，而其余方法不会。

同时，本作品对自身的边界做了诚实陈述：检测效果有限、电池侧缺少真实故障标签、"训练数据无故障"的前提未获证实、尺度修正属开发复验、数据许可限制商业用途。**本作品交付的是可运行、可复用、可检查的技术基础，不代表已经满足全部生产条件，也不主张领先性能。**

5.2 展望

下一阶段的工作方向明确且可执行：

- **取得事件级真值。**这是最有价值的一步：一旦获得电池包的故障事件记录与可信时间映射，即可在本作品现成的严格评价协议上直接计算真实故障召回率、提前量、事件延迟与单体定位准确率——流程不需要改动，只缺标签。在此之前，任何"召回率"表述都是不成立的。
- **扩展到完整数据域。**SMD 从 3 台扩展到全部 28 台；电池测试缓存已具备 14 包、69216 窗的规模，可在冻结模型后做逐包评价。
- **设计真正独立的盲验。**冻结源码与阈值后，在新的、此前未查看的数据域上评价，以替代当前的开发复验，并在多随机种子下给出置信区间。
- **把对比度诊断产品化。**将 4.3 节的距离对比度测量做成迁移前的预检步骤，使其成为复用流程的标准一环。
- **在合规前提下扩展学科。**本作品的特征模式与评价协议与具体物理量无关，具备扩展到工业设备、环境监测等其他多通道时序场景的接口基础；但每一次扩展都需要新的正常参考数据与重新校准，本作品不承诺自动迁移。

参考文献

1. Breunig M M, Kriegel H-P, Ng R T, Sander J. LOF: Identifying Density-Based Local Outliers. Proceedings of the 2000 ACM SIGMOD International Conference on Management of Data, 2000: 93–104. DOI: 10.1145/342009.335388.
2. Pimentel M A F, Clifton D A, Clifton L, Tarassenko L. A review of novelty detection. Signal Processing, 2014, 99: 215–249. DOI: 10.1016/j.sigpro.2013.12.026.
3. Leys C, Ley C, Klein O, Bernard P, Licata L. Detecting outliers: Do not use standard deviation around the mean, use absolute deviation around the median. Journal of Experimental Social Psychology, 2013, 49(4): 764–766. DOI: 10.1016/j.jesp.2013.03.013.
4. Schmidl S, Wenig P, Papenbrock T. Anomaly Detection in Time Series: A Comprehensive Evaluation. Proceedings of the VLDB Endowment, 2022, 15(9): 1779–1797. DOI: 10.14778/3538598.3538602.
5. Liu F T, Ting K M, Zhou Z-H. Isolation Forest. 2008 Eighth IEEE International Conference on Data Mining (ICDM), 2008: 413–422. DOI: 10.1109/ICDM.2008.17.
6. Su Y, Zhao Y, Niu C, Liu R, Sun W, Pei D. Robust Anomaly Detection for Multivariate Time Series through Stochastic Recurrent Neural Network. Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD), 2019: 2828–2837. DOI: 10.1145/3292500.3330672.
7. Schaeffer J, Lenz E, Gulla D, Bazant M Z, Braatz R D, Findeisen R. Gaussian process-based online health monitoring and fault analysis of lithium-ion battery systems from field data. Cell Reports Physical Science, 2024, 5(11): 102258. DOI: 10.1016/j.xcrp.2024.102258.

数据与第三方材料声明

本作品使用的电池相关公开数据集为 “Lithium-Ion Battery Field Data: 28 LFP battery systems with 8 cells in series, up to 5 years of operation” , DOI: 10.5281/zenodo.13715694, 许可 **CC-BY-NC-4.0** (须署名, 不得商用)。服务器监控数据来自 NetManAI/Ops/OmniAnomaly 的 ServerMachineDataset^[6], 上游为 **MIT** 许可。本作品不随交付分发任何数据、模型或逐点预测; 库实现未复制第三方模型代码。